

## Connectivité des graphes aléatoires

*sujet proposé par L. Massoulié*

laurent.massoulie@inria.fr

On s'intéresse à des graphes aléatoires dits d'Erdős-Rényi. Par définition un tel graphe de paramètres  $n \in \mathbb{N}$  et  $p \in [0, 1]$ , qu'on note  $\mathcal{G}(n, p)$  est constitué de  $n$  sommets, qu'on identifie à  $[n] := \{1, \dots, n\}$ , et pour chaque paire non orientée de sommets  $(u, v) \in [n]$ ,  $u \neq v$ , l'arc  $(u, v)$  est présent dans le graphe avec probabilité  $p$ , indépendamment de la présence des autres arcs.

Un graphe est connecté si et seulement si il est constitué d'une unique composante connexe, i.e. de chaque sommet  $u$  il existe un chemin d'arcs dans le graphe le reliant à tout autre sommet  $v$ .

On s'intéresse à la probabilité que le graphe  $\mathcal{G}(n, p)$  soit connecté. Un résultat dû à Erdős et Rényi établit que pour toute constante  $c \in \mathbb{R}$ , on a :

$$\lim_{n \rightarrow \infty} \mathbb{P}(\mathcal{G}(n, (\ln(n) + c)/n) \text{ connecté}) = e^{-e^{-c}}. \quad (20.1)$$

Ceci montre que les graphes d'Erdős-Rényi  $\mathcal{G}(n, p)$  sont connectés avec probabilité approchant 1 si le degré moyen des sommets  $D := (n-1)p$  vérifie  $D - \ln(n) \gg 1$  (i.e.  $c$  positif et grand), tandis qu'ils sont déconnectés avec probabilité approchant 1 si  $\ln(n) - D \gg 1$  (i.e.  $c$  négatif et grand en valeur absolue). On considère une constante  $c \in \mathbb{R}$  fixée, on pose  $p = (\ln(n) + c)/n$  et on considère une réalisation  $G$  de  $\mathcal{G}(n, p)$ .

On dit qu'un sommet  $u$  est isolé s'il n'a aucun voisin (en d'autres termes, si son degré est nul). Pour tout  $u \in [n]$  on pose  $Z_u = \mathbf{1}_u$  sommet isolé de  $G$ . Enfin on note  $X = \sum_{u \in [n]} Z_u$  le nombre des sommets isolés dans le graphe.

Pour un entier  $k$  fixe, on note  $X^{\underline{k}} = X(X-1) \cdots (X-k+1)$ .

**T1.** Montrer que pour tout  $k \in \mathbb{N}$ , on a

$$\begin{aligned} \mathbb{E}(X^{\underline{k}}) &= \sum_{u_1, \dots, u_k} \mathbb{E}(Z_{u_1} \cdots Z_{u_k}) \\ &= n^{\underline{k}} \mathbb{E}(Z_1 \cdots Z_k) \\ &= n^{\underline{k}} (1-p)^{k(n-k) + \binom{k}{2}} \end{aligned}$$

où la somme porte sur toutes les suites d'entiers distincts  $u_1, \dots, u_k$  de  $[n]$ , et en déduire :

$$\lim_{n \rightarrow \infty} \mathbb{E}(X^{\underline{k}}) = e^{-k^2 c}.$$

On admettra que cette convergence pour tout  $k \in \mathbb{N}$  des moments descendants  $\mathbb{E}(X^k)$  de  $X$  vers ceux d'une variable aléatoire de Poisson de paramètre  $\lambda = e^{-c}$  lorsque  $n \rightarrow \infty$  entraîne la convergence en loi de  $X$  vers la loi de Poisson de paramètre  $e^{-c}$ .

**T2.** En déduire que la probabilité  $\mathbb{P}(X = 0)$  que  $\mathcal{G}(n, p)$  n'ait aucun sommet isolé vérifie

$$\lim_{n \rightarrow \infty} \mathbb{P}(X = 0) = e^{-e^{-c}}. \quad (20.2)$$

**T3.** Montrer que pour un entier  $k > 1$ , la probabilité que  $\mathcal{G}(n, p)$  ait une composante connexe de taille  $k$  est majorée par:

$$\binom{n}{k} \mathbb{P}([k] \text{ composante connexe de } \mathcal{G}(n, p)) = \binom{n}{k} \mathbb{P}(\mathcal{G}(k, p) \text{ connecté}) (1-p)^{k(n-k)}. \quad (20.3)$$

On peut alors majorer grossièrement  $\mathbb{P}(\mathcal{G}(k, p) \text{ connecté})$  par  $T_k p^{k-1}$ , où  $T_k$  est le nombre d'arbres sur  $[k]$ , et  $p^{k-1}$  est la probabilité que chacun des  $k-1$  arcs d'un arbre particulier sur  $[k]$  est présent dans  $\mathcal{G}(k, p)$ .

Un théorème de Cayley établit que  $T_k = k^{k-2}$ ; la borne donnée en (20.3) est donc à son tour majorée par:

$$\binom{n}{k} k^{k-2} p^{k-1} (1-p)^{k(n-k)}.$$

De cette majoration, on peut déduire que

$$\lim_{n \rightarrow \infty} \mathbb{P}(\mathcal{G}(n, p) \text{ a une composante connexe de taille } k \in \{2, \dots, n-2\}) = 0.$$

**T4.** Etablir que cette dernière propriété, combinée avec le résultat (20.2) de la première question, implique le résultat d'Erdős-Rényi (20.1).

**S1.** Ecrire un programme qui détermine si un graphe non orienté  $G$  est connexe.

Réaliser une vingtaine de simulations de  $\mathcal{G}(n, p)$  pour  $n = 1000$  et pour chaque valeur de  $p = k/n$ ,  $k = 6.5, 7.0, 7.5, 8.0, 8.5, 9.0$ .

**S2.** Comparer, pour chaque valeur de  $p$ , la fraction des graphes simulés qui sont connexes, et comparer cette fraction à  $e^{-e^{-c}}$ , pour  $c = np - \ln(n)$ . Le résultat asymptotique (20.1) d'Erdős-Rényi fournit-il une bonne approximation de  $\mathbb{P}(\mathcal{G}(n, p) \text{ connecté})$  pour les valeurs de  $n$  et  $p$  considérées?

On considère maintenant un graphe orienté  $\mathcal{G}'(n, p)$  sur les  $n$  sommets  $[n]$ , où chaque arc orienté  $(u, v)$ ,  $u \neq v$  est présent avec probabilité  $p$ , et ce indépendamment de la présence des autres arcs. Chaque sommet  $u$  du graphe a alors un degré entrant  $d_u^{in} = \sum_{v \neq u} \mathbf{1}_{\text{arc } (v, u) \text{ présent}}$ , et un degré sortant  $d_u^{out} = \sum_{v \neq u} \mathbf{1}_{\text{arc } (u, v) \text{ présent}}$ . On note alors  $X_{in}$  (respectivement,  $X_{out}$ ) le nombre de sommets  $u \in [n]$  de degré rentrant  $d_u^{in}$  (respectivement, sortant  $d_u^{out}$ ) égal à zéro.

**T5.** Justifier brièvement que, pour  $p = (\ln(n) + c)/n$  avec  $c \in \mathbb{R}$  fixé,  $X_{in}$  et  $X_{out}$  ont une loi binomiale de paramètres  $(n-1, (1-p)^{n-1})$ , et que celle-ci tend vers la loi de Poisson de paramètre  $e^{-c}$  lorsque  $n \rightarrow \infty$ .

On dit qu'un graphe orienté est fortement connexe si pour toute paire de sommets distincts  $u, v$ , il existe

un chemin orienté allant de  $u$  à  $v$ . Une condition nécessaire pour qu'un graphe soit fortement connexe est que chaque sommet  $u$  ait ses degrés entrant  $d_u^{in}$  et sortant  $d_u^{out}$  non nuls.

Un argumentaire semblable à celui fait pour les graphes non-orientés établit que, pour  $p = (\ln(n) + c)/n$  et  $c \in \mathbb{R}$  fixé, on a

$$\lim_{n \rightarrow \infty} \mathbb{P}(\mathcal{G}'(n, p) \text{ connexe}) = \lim_{n \rightarrow \infty} \mathbb{P}(X_{out} = X_{in} = 0) = e^{-2e^{-c}}. \quad (20.4)$$

**S3.** Ecrire un programme déterminant si un graphe orienté est fortement connexe. Tester, pour  $n = 1000$  et  $p = k/n$ ,  $k = 6.5, 7.0, 7.5, 8.0, 8.5$ , la validité de la formule asymptotique (20.4) en simulant une vingtaine de graphes  $\mathcal{G}'(n, p)$  pour les paramètres correspondants.

---